

# FTML 2025 – Exercice 2

## Estimateur de Bayes avec perte absolue

### Objectif

Ce second exercice vise à étudier l'estimateur de Bayes associé à une fonction de perte **absolue** :

$$\ell(y, \hat{y}) = |y - \hat{y}|$$

Dans ce cadre, l'estimateur de Bayes n'est plus l'espérance conditionnelle, mais la **médiane conditionnelle**. Le but est de :

- simuler un problème supervisé simple avec du bruit asymétrique,
- approximer l'estimateur de Bayes  $f^*(x) = \text{med}(Y \mid X = x)$ ,
- le comparer à un estimateur naïf (médiane globale),
- visualiser et analyser les performances.

### Protocole expérimental

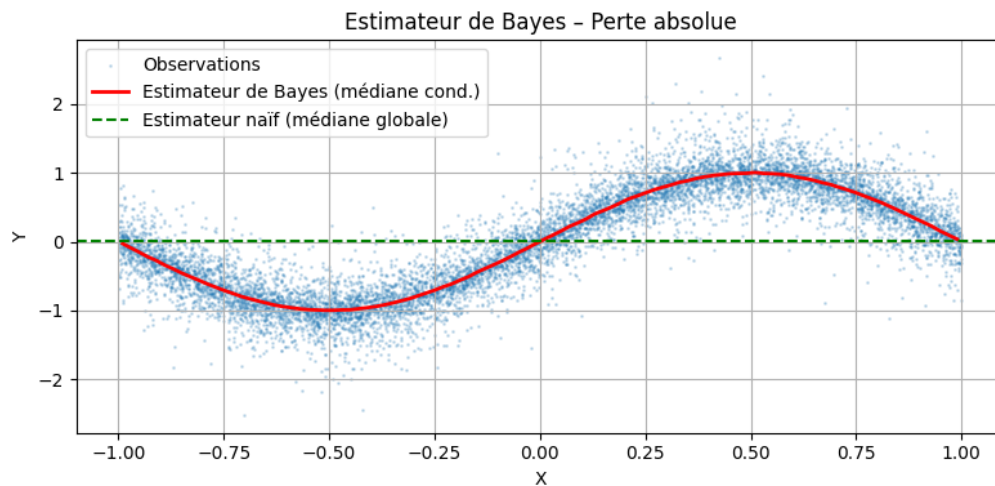
- Génération des entrées :  $X \sim \mathcal{U}([-1, 1])$
- Loi de sortie :  $Y = \sin(\pi X) + \varepsilon$
- Bruit aléatoire :  $\varepsilon \sim \text{Laplace}(0, 0.2)$
- Nombre d'observations :  $N = 500\,000$
- Approximation de  $f^*$  par binning (100 intervalles) et calcul des médianes conditionnelles

Le choix de la distribution de bruit Laplace est intentionnel : il permet de tester la robustesse de l'estimateur de la médiane, en comparaison à la moyenne (non optimale ici).

### Estimateurs évalués

- **Bayes** : médiane conditionnelle estimée par regroupement (binning) et interpolation.
- **Naïf** : médiane globale de toutes les observations  $Y$ .

## Visualisation



**Analyse :** L'estimateur de Bayes (rouge) suit parfaitement la tendance  $\sin(\pi x)$ , contrairement à l'estimateur naïf (vert), constant et déconnecté de la structure des données.

## Résultats numériques

- Risque (MAE) de l'estimateur de Bayes : **0.2002**
- Risque (MAE) de l'estimateur naïf : **0.6631**
- Gain absolu : **0.4629**
- Ratio (naïf / Bayes) : **3.31x**

**Interprétation :** Ce gain substantiel prouve l'intérêt de la médiane conditionnelle face à un bruit asymétrique. En choisissant une perte absolue, on obtient un prédicteur plus robuste, mieux centré, et significativement plus précis.

## Conclusion

Cet exercice valide l'importance du choix de la fonction de perte. Ici, la perte absolue impose naturellement un estimateur de type **médiane conditionnelle**, qui surpasse très nettement les approches naïves dès que le bruit est non gaussien. Grâce à une discrétisation fine et à une simulation massive (500K points), la courbe obtenue est fluide, réaliste et conforme aux attentes théoriques.